

# 基于改进 FCN 的车道线检测研究<sup>\*</sup>

杨 莹,何志琴

(贵州大学电气工程学院,贵阳 550025)

**摘 要:**为提高车道线检测的准确性以增强无人驾驶车辆的安全驾驶性能,在传统车道线检测的边缘提取、霍夫变换、颜色空间阈值提取、透视变换等方法的基础上,利用深度学习技术,提出一种基于改进 FCN 的车道线检测网络模型。该模型能够准确提取出车道线的特征信息,并在车道线检测数据集上进行模型训练,以评估该车道线检测网络的性能。通过实验对比,结果表明改进 FCN 模型在检测精度上比传统 FCN 网络模型提高了 1%,具有良好的分割有效性。

**关键词:**无人驾驶;深度学习;图像分割;FCN 模型

**DOI:** 10.3969/j.issn.1002-2279.2022.01.008

**中图分类号:** TP391.4

**文献标识码:** A

**文章编号:** 1002-2279(2022)01-0030-04

## Research on Lane Line Detection Based on Improved FCN

YANG Ying, HE Zhiqin

(The Electrical Engineering College, Guizhou University, Guiyang 550025, China)

**Abstract:** In order to improve the accuracy of lane line detection and enhance the safe driving performance of driverless vehicles, a lane line detection network model based on improved FCN is proposed by using deep learning technology on the basis of traditional lane detection methods such as edge extraction, Hough transform, color space threshold extraction and perspective transform. The model can accurately extract the feature information of the lane line, and train the model on the lane line detection data set to evaluate the performance of the lane line detection network. Experimental comparison shows that the detection accuracy of the improved FCN model is 1% higher than that of the traditional FCN network model, and it has good segmentation effectiveness.

**Key words:** Driverless driving; Deep learning; Image segmentation; FCN model

## 1 引 言

近年来,随着无人驾驶技术的深入发展,无人驾驶车辆等新兴的智能交通工具都处在实验落跑进程中。如何有效地检测出道路标识线、保障车辆的安全行驶,目前仍是人工智能方向的研究热点<sup>[1]</sup>。车道线是车辆行驶路面的重要交通标志,能否准确识别出车道线决定着车辆的行驶安全性能。传统的车道线检测方法主要包括特征法<sup>[2]</sup>与模型法<sup>[3]</sup>等。随着深度神经网络在图像处理领域受到广泛应用,一些经典的分割网络也被应用到车道线的检测中,例如 MASK<sup>[4]</sup>、R-CNN<sup>[5]</sup>、FCN<sup>[6]</sup>、Unet<sup>[7]</sup>等,皆在车道线检测中均表现出不俗的检测性能。深度学习的方法不仅大大提高了检测的准确率,也加快了检测速率。

在现有研究成果的基础上,在此提出一种基于改进 FCN 网络的车道线分割算法。对 FCN 的特征提取网络做出改进,包括加深网络层数和修改卷积核个数;引入 Unet 网络并跳跃连接,将编码层的特征图与解码层的特征图进行连接,实现输出结果与多层语义信息的结合;以 Conv2DTranspose 代替网络层中的 UpSampling2D 来实现上采样。由于存在学习的过程,可实现更好的分割效果。

## 2 FCN 网络原理

FCN 是深度学习网络,作为图像分割应用的基础,它是一种“端到端”的图像分割方法,其网络中所有的层都是卷积层<sup>[8]</sup>。

FCN 网络从像素级别上实现了对图像特征的分

<sup>\*</sup>基金项目:黔科合 LH 字[2017]7229;黔科合基础[2018]1029

作者简介:杨莹(1996—),女,湖北省孝感市人,硕士研究生,主研方向:图像处理技术。  
通讯作者:何志琴(1974—),女,贵州省贵阳市人,硕士,教授,主研方向:电力电子技术。  
收稿日期:2021-06-08

类,从而实现图像的语义分割。经典的卷积神经网络通常是在卷积层之后添加全连接层,将输出特征表示为一定长度的特征向量,然后再对其进行概率预测从而实现分类。相比之下,FCN 与之不同之处在于逐层卷积层提取特征图后,会采用逐个反卷积

将最后一个卷积层输出的特征图进行逐层上采样,最终的输出图像是与原图像素数目相同的特征图,从而实现在原图上对每个像素点的语义预测,同时也保留了原图上的空间信息。传统的 FCN 网络结构如图 1 所示。




图 1 FCN 网络结构原理图

### 3 网络结构改进

由于 FCN 网络本身结构限制,上下文信息不足,可能存在梯度消失等问题;在上采样过程中需要插值填补空白区域,需要更多的辅助信息,将该网络应用到车道线检测中,此类问题亟待解决。更深层的卷积操作能更有效地提取特征,适当地增加网络层数并修改卷积核个数能获得更多的语义信息,结合并联跳跃结构就能融合不同维度的特征,逆卷积的替换也让输出层信息表达更加丰富。

#### 3.1 网络层数与并联跳跃结构

卷积层、逆卷积层的适当增加能提取更高维度的特征信息并使输出图像信息更加丰富;增加卷积核个数即增加每个卷积层滤波器的数量,能获得每个输入特征上更多的语义信息。

单纯的“编码器-解码器”架构在编码过程中会压缩或丢失大量细节信息,其中包括对于分割任务非常重要的空间域信息,这些信息的丢失会大大影响解码过程中分割任务的好坏,不利于精确的分割掩膜的生成。

并联跳跃结构将编码器结构中卷积层得到的特征图“接合”(concatenate)到对应的上采样层,使得各卷积层输出的特征图能被有效地利用到后续计算中。它通过将浅层的卷积层连接到对应的上采样层,从而结合低等级特征图中的特征,使得最终所得到的特征图中既包含高等级的特征,也包含了很多低等级的特征,实现不同规模下的特征融合,更有利于生成分割掩膜。

改进后的包含并联跳跃结构的网络模型如图 2 所示。图中横向两层的连接即为卷积层对应连接到上采样层。

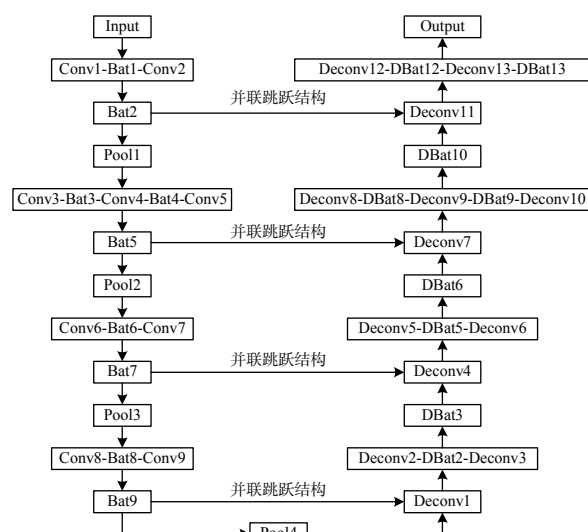


图 2 并联跳跃结构网络

#### 3.2 逆卷积

Conv2DTranspose 是正常卷积的反向操作,通过可学习的参数获得更好的卷积效果。这一逆卷积过程如图 3 所示。




图 3 逆卷积过程示意图

UpSampling2D 是 Pooling 的反向操作,通过采用最近邻插值法来将输入特征图进行放大,主要通过复制行和列的数据来进行扩充。反向梯度传播的时候,插值取每个单元格的梯度之和。

譬如,给定一个特征图  $a$ ,高和宽分别表示为  $H_a$  和  $W_a$ ,相应的卷积核设置为:卷积核尺寸  $M_H \times M_W$ ,步长为  $S$ ,零填充为  $P$ 。逆卷积操作分为三步进行:

第一步:在特征图  $a$  原先高度和宽度方向的每两个相邻像素间插上  $S-1$  列 0,得到特征图  $b$ ;特征图  $b$  的宽和高分别表示为  $H_b = H_a + (S-1)(H_a-1)$ 、 $W_b = W_a + (S-1)(W_a-1)$ 。

第二步:设置新的卷积核: $S' = 1$ ,卷积核大小仍为  $M_H \times M_W$  不变, $P' = S - P - 1$ 。

第三步:用新的卷积核在特征图  $b$  上做卷积运算,得到的结果就是逆卷积的结果,亦即要求的结果特征图  $c$  的大小。

上述过程的简单推导可概括为下式:

$$H_c = \frac{(H_a + 2P' - M_H)}{S'} + 1 \quad (1)$$

代入特征图  $b$  及新卷积核设置,进一步化简为:

$$H_c = (H_a - 1)S - 2P + M_H \quad (2)$$

特征图  $c$  的宽度  $W_c$  同理可得。

#### 4 网络模型训练实验及结果分析

实验操作系统为 Windows 10;深度学习框架为 TensorFlow 2.0.0;Python 版本为 3.6.8;显卡为 NVIDIA V100。

深度神经网络模型训练需要大量优良数据的支撑。车道线数据集中包含结构化路面及高速公路车道线图片,给网络提供了真实的标准数据,确保卷积神经网络的数据得到更好的拟合。网络训练过程中,通过将网络预测的结果与真实结果进行对比获取损失值,同时自动地调整模型权重,使模型输出预测值逐渐接近真实值,实现车道线的分割检测任务。因此,需要有标签 Label 记录标注点的位置,并且将数据划分为训练集、验证集,之后再对模型进行预训练,并将预训练模型在数据集上进行调优与测试。

分别对改进前后的分割网络进行训练,共包含训练集 5400 张、测试集 720 张。深度学习框架选用 TensorFlow,优化策略为 Adam,初始学习率为 0.001, batch\_size 为 16,迭代次数(epoch)为 200 次。通过

200 次的迭代,改进前的网络结构平均准确率为 82%,改进后的网络结构平均准确率为 83%,比之前精度提升了 1%,对模型的特征提取能力有一定的提升;改进前的网络模型的损失函数值为 0.0097,改进后的损失函数值为 0.0053,改进后的网络模型的 loss 收敛效果更佳。

获取两种 FCN 网络模型后,分别在同一环境中对车道线进行测试,测试效果如图 4 所示。改进后的 FCN 网络模型的分割精度比原模型的分割网络提高 1%,进一步验证了改进模型的有效性。



(a) 改进前



(b) 改进后

图 4 改进前后网络测试效果对比

#### 5 结 束 语

在 FCN 网络的基础上,增加网络层数并修改卷积核个数,提取出更多的语义信息,采用并联跳跃结构将 encoding 的 feature map 与 decoding 的 feature map 进行连接,可以在进行分类预测时利用多层信息,将 UpSampling2D 改为 Conv2DTranspose 实现上采样的过程,获得了更好的分割效果。改进后的网络结构与原来的网络结构在分类精度上有所提高,在分割精度上也有一定的提升。后续研究中,还应进一步提高训练集数据的丰富度,增强模型的泛化能力。

##### 参考文献:

- [1] MCCALL J C, TRIVEDI M M. Video-based lane estimation and tracking for driver assistance:survey, system, and eva-

- uation[J]. IEEE Transactions on Intelligent Transportation Systems, 2006, 7(1):20–37.
- [2] HILLEL A B, LERNER R, LEVI D, et al. Recent progress in road and lane detection:a survey[J]. Machine Vision and Applications, 2014, 25(3):727–745.
- [3] 许华荣, 王晓栋, 方遒. 基于 B 样条曲线模型的结构化道路检测算法[J]. 自动化学报, 2011, 37(3):270–275.  
XU Huarong, WANG Xiaodong, FANG Qiu. Structure road detection algorithm based on B-spline curve model[J]. Acta Automatica Sinica, 2011, 37(3):270–275.
- [4] 徐国晟, 张伟伟, 吴训成, 等. 基于卷积神经网络的车道线语义分割算法[J]. 电子测量与仪器学报, 2018, 32(7):89–94.  
XU Guosheng, ZHANG Weiwei, WU Xuncheng, et al. Lane-line semantic segmentation algorithm based on convolutional neural network[J]. Journal of Electronic Measurement and Instrumentation, 2018, 32(7):89–94.
- [5] HE Kaiming, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN[C]//2017 IEEE International Conference on Computer Vision (ICCV), October 22–29, 2017, Venice, Italy. IEEE, 2017:2980–2988.
- [6] LONG J, SHELHAMER E, DARRELL T. Fully convolutional networks for semantic segmentation[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 7–12, 2015, Boston, MA, USA. IEEE, 2015: 3431–3440.
- [7] RONNEBERGER O, FISCHER P, BROX T. U-Net:Convolutional Networks for Biomedical Image Segmentation[Z]. arXiv:1505.04597v1 [cs.CV] 18 May 2015.
- [8] 田萱, 王亮, 丁琪. 基于深度学习的图像语义分割方法综述[J]. 软件学报, 2019, 30(2):440–468.  
TIAN Xuan, WANG Liang, DING Qi. Review of image semantic segmentation based on deep learning[J]. Journal of Software, 2019, 30(2):440–468.

(上接第 29 页)

## 5 结 束 语

利用残差网络 ResNet-50 对原来的基础网络 VGG-16 进行替代, 再在残差模块中添加注意力机制 CBAM, 确实可对小目标检测效果做出实际性的改善。改进算法中的相关尝试在实际应用中尚有更广的发展潜力。改进后的算法在 KITTI 数据集上的检测结果显示其能够达到更高的精度, 但实际网络结构参数庞大, 后续研究中将尝试通过网络剪枝的方式来降低训练参数的数量, 提高运算速度。

### 参考文献:

- [1] GIRSHICK R. Fast R-CNN[C]//2015 IEEE International Conference on Computer Vision (ICCV), December 7–13, 2015, Santiago, Chile. IEEE, 2015:1440–1448.
- [2] CAI Zhaowei, VASCONCELOS N. Cascade R-CNN:delving into high quality object detection[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, June 18–23, 2018, Salt Lake City, UT, USA. IEEE, 2018:6154–6162.
- [3] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once:unified, real-time object detection[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 27–30, 2016, Las Vegas, NV, USA. IEEE, 2016:779–788.
- [4] LIU Wei, ANGUELOV D, ERHAN D, et al. SSD:single shot multibox detector[C]//LEIBE B, et al. ECCV 2016, Part I, LNCS 9905. New York:Springer International Publishing AG, 2016:21–37.
- [5] HE Kaiming, ZHANG Xiangyu, REN Shaoqing, et al. Deep residual learning for image recognition[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 27–30, 2016, Las Vegas, NV, USA. IEEE, 2016:770–778.
- [6] 汪慧兰, 戴舒, 刘丹, 等. 交通场景中改进 SSD 算法的小尺度行人检测研究[J/OL]. 计算机工程与应用, 2021:1–8 [2021-03–31]. <https://kns.cnki.net/kcms/detail/11.2127.TP.20210331.1020.010.html>.
- WANG Huilan, DAI Shu, LIU Dan, et al. Small-scale pedestrian detection in traffic scenes based on improved SSD algorithm[J/OL]. Computer Engineering and Applications, 2021:1–8[2021-03–31]. <https://kns.cnki.net/kcms/detail/11.2127.TP.20210331.1020.010.html>.
- [7] FU Chengyang, LIU Wei, RANGA Ananth, et al. DSSD:deconvolutional single shot detector[Z]. arXiv:1701.06659v1 [cs.CV] 23 Jan 2017.
- [8] WOO Sanghyun, PARK Jongchan, LEE Joonyoung, et al. CBAM:convolutional block attention module[C]//FERRARI V, et al. ECCV 2018, LNCS 11211. New York:Springer International Publishing AG, 2018:3–19.
- [9] 胡少晖, 王修晖. 结合注意力卷积网络与分块特征的步态识别[J/OL]. 计算机工程与应用, 2021:1–11[2021-03–17]. <https://kns.cnki.net/kcms/detail/11.2127.TP.20210316.1733.012.html>.