



兵器装备工程学报
Journal of Ordnance Equipment Engineering
ISSN 2096-2304, CN 50-1213/TJ

《兵器装备工程学报》网络首发论文

题目: 基于改进 YOLOv4 算法的无人机目标检测
作者: 祁江鑫, 吴玲, 卢发兴, 史浩然, 许俊飞
收稿日期: 2021-08-14
网络首发日期: 2022-04-27
引用格式: 祁江鑫, 吴玲, 卢发兴, 史浩然, 许俊飞. 基于改进 YOLOv4 算法的无人机目标检测[J/OL]. 兵器装备工程学报.
<https://kns.cnki.net/kcms/detail/50.1213.TJ.20220427.1555.015.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于改进 YOLOv4 算法的无人机目标检测

祁江鑫, 吴玲, 卢发兴, 史浩然, 许俊飞

(海军工程大学, 武汉, 430000)

摘要: 无人机检测是实现无人机集群精准打击的重要前提。为了提高无人机集群检测精度和速度, 提出了基于改进 YOLOv4 无人机集群目标检测方法。首先使用轻量化网络 MobileNetV3 分别获得 5 个有效特征层来代替原网络中主特征提取网络生成的有效特征层, 来降低原网络的参数量和计算量; 然后采用改进的 k-means 优化聚类先验框替代原算法中的先验框; 最后基于公共数据集验证了算法的有效性, 在单无人机和无人机集群 2 种情况下进行了无人机检测实验。实验结果表明: 使用轻量化网络并利用改进 k-means 优化聚类先验框的改进 YOLOv4 算法相比传统 YOLOv3 和 YOLOv4 算法在无人机检测精度和检测速度上有明显提升, 其中检测精度相比较 YOLOv3 和 YOLOv4 分别提高了 16.4%、7.3%, 检测速率分别是 YOLOv3 和 YOLOv4 的 1.82 倍、2.27 倍, 漏检率分别降低了 68.5%、6.25%, 误检率分别降低了 69.8%、62.2%, 有效解决了无人机检测中出现的误检和漏检等问题; 与其他深度学习算法 SSD 和 Centernet 相比, 检测精度分别提高了 15.4%、19.4%, 检测速率分别提高了 16.4%、52.1%。

关键词: 深度学习; 轻量化网络; 无人机; 集群检测; 改进 YOLOv4; 改进 k-means

中图分类号: TP273

文献标志码: A

UAV cluster detection based on improved YOLOv4 algorithm

QI Jiangxin, WU Ling, LU Faxing, SHI Haoran, XU Junfei

(Naval Engineering University, Wuhan 430000, China)

Abstract: UAV detection is an important prerequisite to achieve accurate attack on UAV cluster. In order to improve the accuracy and speed of UAV cluster detection, an improved method of UAV cluster target detection based on YOLOv4 is proposed. Firstly, the lightweight network mobilenetv3 is used to obtain five effective feature layers to replace the effective feature layer generated by the main feature extraction network in the original network, so as to reduce the amount of parameters and calculation of the original network. Then, the improved K-means is used to optimize the clustering prior. Firstly, the effectiveness of the algorithm is verified based on the common data set, and then the UAV detection experiments are carried out in the case of single UAV and UAV cluster. The results show that the improved yolov4 algorithm using lightweight network and using improved k-means to optimize clustering prior frame has significantly improved the accuracy and detection speed of UAV compared with traditional yolov3 and yolov4 algorithms. The detection accuracy is 16.4% and 7.3% higher than yolov3 and yolov4 respectively, and the detection rate is 1.82 times and 2.27 times of yolov3 and yolov4, and the missed detection rate is 68.5% The error detection rate decreased 69.8% and 62.2% respectively, which effectively solved the problems of false inspection and missed inspection in UAV detection; Compared with other deep learning algorithms SSD and centernet, the detection accuracy is improved by 15.4%, 19.4% and the detection rate is increased by 16.4% and 52.1% respectively.

Key words: deep learning; lightweight network; UAV; cluster detection; improved YOLOv4; improved k-means

1 引言

随着武器装备技术的发展, 无人机在现代战争发挥越来越重要的角色。快速准确地检测出无人机

集群目标, 是对其成功拦截的前提, 也是迫切需要解决的现实问题。目前对于无人机集群的检测, 有许多优秀的算法, 例如 R-CNN^[1]、Fast R-CNN^[2]、

收稿日期: 2021-08-14 作者简介: 祁江鑫 (1995-), 男, 硕士, email: 2335653859@qq.com.

通信作者: 吴玲 (1976-), 女, 博士, 副教授, email: xjf09531@163.com.

SSD^[3]、YOLO^[4]等,这些算法都有各自的优缺点,主要是由于检测精度和检测速度是一对矛盾体,高的检测精度意味着网络结构复杂,网络结构复杂意味着检测速度受限。

为了平衡检测精度与检测速度,提出了系列改进的YOLO^[4]算法,如YOLOv2^[5]、YOLOv3^[6]、YOLOv4^[7]等,其中YOLOv4算法结合了许多优秀的目标检测算法,加以组合并进行创新,实现了检测速度和检测精度的平衡,但在未来对空防御无人机集群作战中,考虑到武器反应时间,还需要进一步提高无人机集群的检测速度。为了提高检测速度,目前轻量化网络得到快速发展,该类网络旨在保持模型精度基础上进一步减少模型参数量和复杂度,进而实现网络模型加速。该类网络主要有网络结构设计和模型压缩2类,其中模型压缩主要是对已有的网络进行剪枝、知识蒸馏等方式使网络结构简单,而另一类是直接采用轻量化思想进行网络结构设计,例如MobileNet系列^[8]。相比于已训练好的模型上进行处理,轻量化模型模型设计是另辟蹊径,主要思想在于设计更高效的网络计算方式,从而使网络参数减少的同时,不损失网络性能。

2 YOLOv4 算法改进

YOLOv4算法采用3个特征层进行分类和回归预测,主要由3个部分组成:主干特征提取网络CSPDarknet53、加强特征提取网络SPP+PANet和预测网络Yolo Head。具体网络模型结构如图1所示。

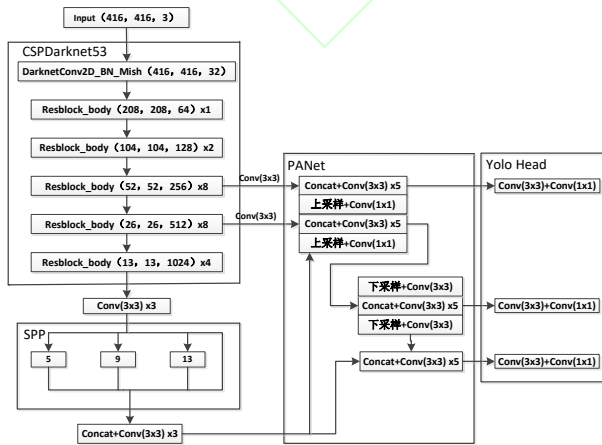


图 1 YOLOv4 网络模型结构

Fig. 1 YOLOv4 network model structure

主干特征提取网络CSPDarknet53主要有2个方

面改进:在YOLOv3中Darknet53的Resblock_body加入CSPnet结构;同时DarknetConv2D的激活函数改为Mish激活函数。在特征金字塔方面,主要是采用了SPP+PANet的结构,其中SPP结构是对最后一个特征层经过3次卷积结果进行不同尺度的最大池化处理,其对应的池化核大小分别为 1×1 、 5×5 、 9×9 、 13×13 ,可以极大提高感受野,分离出显著目标特征。而PANet结构主要是通过2次上采样和下采样来进行特征反复提取,进而完成多次特征融合。在预测网络Yolo Head方面,主要是通过2次 3×3 和 1×1 的标准卷积,来完成预测框的生成,同时还包括判断预测框中是否包含目标以及目标的种类。

2.1 改进YOLOv4网络结构

2.1.1 MobileNetV3网络

YOLOv4网络结构过于复杂,虽然检测精度高,但是检测速度相对较低,为了在保持相同检测精度的同时,进一步提高检测速度,采用轻量化的深度学习网络对主干特征提取网络进行优化。其中MobileNet系列是轻量化网络的典型代表,主要有MobileNetV1、MobileNetV2和MobileNetV3等3个版本,其中MobileNetV3网络是在MobileNetV2的基础上使用神经架构搜索技术生成的结构,其主要有以下2个方面改进^[9]:①引入轻量级的注意力模型,该模型的作用是用于调整每个通道的权重。②利用h-swish激活函数代替swish函数,减少运算量,提高性能。

2.1.2 改进PANet结构

对于PANet网络而言,整个网络的参数运算量主要集中在 3×3 的标准卷积上,为了进一步减少网络参数量,将该结构中标准卷积全部使用深度可分离卷积代替,深度可分离卷积实质是将标准卷积转化为一个深度卷积和一个逐点卷积进行运算^[10],其具体的过程如图2所示。




图 2 深度可分离卷积

Fig.2 Deep separable convolution

图2中,左侧为标准卷积、右侧为深度可分离卷积。假设图片输入特征图大小为 $D_K \times D_K \times M$,卷积核大小为 $D_K \times D_K \times M \times N$,输出特征图大小为 $D_F \times D_F \times N$ 。对于标准卷积而言,其参数数量为: $D_K \times D_K \times M \times N$,计算量为: $D_K \times D_K \times M \times N \times D_F \times D_F$;而深度可分离卷积其参数数量为: $D_K \times D_K \times M + M \times N$,计算量为: $D_K \times D_K \times M \times D_F \times D_F + M \times N \times D_F \times D_F$ 。将两者所对应的数据进行对比分析,在参数量对比上有如下关系:

$$\frac{D_K \times D_K \times M + M \times N}{D_K \times D_K \times M \times N} = \frac{1}{N} + \frac{1}{D_K^2}$$

计算量对比有如下关系:

$$\frac{D_K \times D_K \times M \times D_F \times D_F + M \times N \times D_F \times D_F}{D_K \times D_K \times M \times N \times D_F \times D_F} = \frac{1}{N} + \frac{1}{D_K^2}$$

由对比结果可以发现,使用深度可分离卷积之后,其对应的参数量和计算量均下降为原来的 $\frac{1}{N} + \frac{1}{D_K^2}$,一般卷积核采用 3×3 ,同时 $N \gg 9$,因而深度可分离卷积的参数量和计算量均为标准卷积的 $1/8-1/9$ 。

2.1.3 改进思路

在YOLOv4的主干特征提取网络中,使用MobileNetV3网络分别获得5个有效特征层来代替原网络。同时为了进一步减少网络参数量,使用深度可分离卷积来代替PANet结构和YOLOv4原网络中其余的标准卷积,其具体的优化网络结构如图3所示。

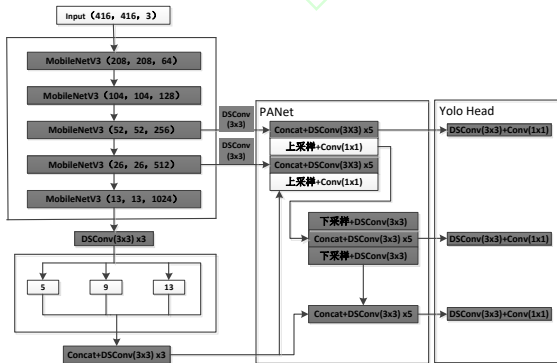


图3 优化网络结构

Fig.3 Optimizing network structure

2.2 改进 K-means 聚类先验框

2.2.1 K-means 聚类先验框

在目标检测的任务中,先验框的选择至关重要,先验框选择的合理与否,直接影响着检测模型性能的好坏。YOLOv4的先验框在特征图上分布情况如表1所示,其默认基于COCO数据集,该数据集中包含80类物体。

表1 YOLOv4 默认先验框在特征图上分布情况
Tab.1 Distribution of yolov4 default a priori frame on characteristic graph

特征图大小	感受野	先验框
13*13	大	(142*110) (192*243) (459*401)
26*26	中	(36*75) (76*55) (72*146)
52*52	小	(12*16) (19*36) (40*28)

该先验框对无人机目标检测针对性不强,容易出现漏检或者定位不准的问题,影响检测精度,需要对先验框做适应性设计,这里采用数据集的格式为VOC。在YOLOv3算法中有文献采用K-means^[11]对数据集进行聚类初始化得到先验框,定义了距离公式为:

$$d(box, centroid) = 1 - IOU(box, centroid) \quad (1)$$

式(1)中:centroid表示聚类中心;box表示样本;IOU表示真实框和样本框的重合程度。该方法也可运用到YOLOv4的无人机集群检测中,利用该方法仿真可得K-means先验框在特征图上分布情况,如表2所示。

表2 K-means 先验框在特征图上分布情况
Tab.2 Distribution of K-means a priori frame on characteristic graph

特征图大小	感受野	先验框
13*13	大	(281*211) (356*174) (363*274)
26*26	中	(198*253) (211*113) (249*344)
52*52	小	(47*41) (126*59) (151*180)

由表2知,先验框分布比较集中,不利于无人机多尺度检测的输出,同样的默认数据的先验框也存在类似的问题。

2.2.2 改进 K-means 聚类先验框

为了进一步解决K-means计算先验框分布集中的问题,发挥多尺度检测的优势,可对先验框进行线性尺度缩放,使无人机的检测输出范围更加宽广,

增加算法的鲁棒性。由 K-means 计算可得无人机的先验框共有 9 个，因而具体线性尺度缩放公式为：

$$\hat{x}_1 = \gamma x_1 \quad (2)$$

$$\hat{x}_9 = \mu x_9 \quad (3)$$

$$\hat{x}_i = \frac{(x_i - x_1) * (\hat{x}_9 - \hat{x}_1)}{\hat{x}_9 - x_1} + \hat{x}_1 \quad (4)$$

$$\hat{y}_i = \frac{y_i}{x_i} * \hat{x}_i \quad (5)$$

式 (2) ~ (5) 中：\$i=2 \dots 9\$；\$\gamma\$ 表示最小先验框的缩放倍数；\$\mu\$ 表示最大先验框的扩大倍数；\$(x_i, y_i)\$ 分别代表线性尺度缩放前对应先验框的宽和高；\$(\hat{x}_i, \hat{y}_i)\$ 代表缩放后先验框的宽和高。经过仿真实验其先验框在特征图上的分布情况如表 3 所示。

表 3 改进 K-means 先验框在特征图上分布情况
Tab.3 Distribution of improved k-means a priori frame on characteristic graph

特征图大小	感受野	先验框
13*13	大	(408*306)(532*260)(544*411)
26*26	中	(271*347)(293*157)(356*491)
52*52	小	(23*20)(153*71)(194*231)

3 检测评价指标

3.1 检测精度 mAP

为了衡量目标检测的效果，引入检测精度和检测速率作为评价指标。引入 IOU 这一指标，表示真实框和样本框的重合程度，如图 4 所示，

$$IOU = \frac{S_{A \cap B}}{S_{A \cup B}}, \text{ 且 } IOU \in (0,1]。$$




图 4 IOU 描述图

Fig.4 IOU description

当 IOU 的值大于某个阈值时，该预测框确定为正样本；反之则为负样本。在一定 IOU 指标下，定义查准率指标^[12]为：

$$P = \frac{TP}{TP + FP} \quad (6)$$

式 (6) 中：TP 代表正确分类的正样本；FP 代表错误分类的正样本。

定义查全率指标^[13]为：

$$R = \frac{TP}{TP + FN} \quad (7)$$

式 (7) 中，FN 代表错误分类的负样本。

引入平均精度 AP^[14] (Average Precision) 为：

$$AP = \int_0^1 P dR \quad (8)$$

式 (8) 中，\$AP_{50}\$ 表征当 IOU 值为 50% 时的 AP 值，\$AP_{60}\$、

\$AP_{70}\$ 等类似定义。

定义所有目标类对应的 AP 值的平均值 mAP 为：

$$mAP = \frac{\sum_{i=1}^N AP_i}{N} \quad (9)$$

式 (9) 中，\$N\$ 表示目标的种类数。采用 mAP 值作为目标检测精度评价指标^[15]。

3.2 正负样本分类指标 F1

在进行目标检测时，查全率和查准率是一对矛盾体，为了平衡查全率和查准率的权重，引入正负样本分类指标为：

$$F_\beta = \frac{(1 + \beta^2)PR}{\beta^2 P + R} \quad (10)$$

式 (10) 中：当 \$\beta=1\$ 时，\$P\$ 和 \$R\$ 同等重要；当 \$\beta > 1\$ 时，\$R\$ 比 \$P\$ 重要；当 \$\beta < 1\$ 时，\$P\$ 比 \$R\$ 重要。

选取 \$\beta=1\$ 来定义目标正负样本分类评价指标，此时记第 \$k\$ 类正负样本分类指标为：

$$F1_k = \frac{2R_k P_k}{R_k + P_k} \quad (11)$$

式 (11) 中，\$P_k\$ 和 \$R_k\$ 分别为第 \$k\$ 类目标的查准率和

查全率。记 F1 为所有目标类对应 \$F1_k\$ 的平均值为：

$$F1 = \left(\frac{\sum_{k=1}^N F1_k}{N} \right)^2 \quad (12)$$

F1 指标可以用于表征正负样本分类难度，F1 越小，正负样本分类难度越高，检测难度也将随之增加。

3.3 检测速率 FPS

将每秒处理图片的帧数 FPS^[16] 作为目标检测速率评价指标。该值越大则目标检测速率越快。

4 实验设计及分析

在实验仿真中,使用 Windows10 操作系统,深度学习框架为 pytorch, CPU 为 Intel (R)Core(TM) i5-8300H, GPU 为 NVIDIA GeForce GTX 1050,CUDA 为 10.1 版本, CUDNN 为 7.4.15 版本。

实验在公共数据集和构建的无人机数据集中分别开展,其中公共数据集样本量大丰富,能可靠验证方法的有效性,构建的无人机数据集则有针对性地解决无人机目标检测的具体问题。

4.1 基于公共数据集的目标检测实验

4.1.1 公共数据集

RSOD-Dataset 数据集,由武汉大学进行标注的公共数据集,用于遥感图像的对象检测,数据集包括飞机、油桶、操场和立交桥。该数据集中有 4993 架飞机、191 个操场、180 个立交桥和 1586 个油桶。

4.1.2 公共数据集实验结果及分析

在公共数据集上,相同条件下验证上述改进算法的效果,其中具体的训练损失如图 5 所示,检测效果图以飞机为例,具体的检测结果如图 6 和表 4 所示。




图 5 公共数据集训练损失图

Fig.5 Training loss of public data set

由图 5 可以看出,当训练到第 50 代时,训练损失已经收敛,达到目标检测的精度要求。



(a) YOLOv4



(b) 轻量化 YOLOv4



(c) k-means+轻量化 YOLOv4



(d) 改进 k-means+轻量化 YOLOv4

图 6 公共数据集飞机检测效果图

Fig.6 Aircraft detection effect of public data set

表 4 不同改进方法下对应检测精度

Tab.4 Corresponding detection accuracy under different improved methods


类别	YOLOv4	YOLOv4	轻量化	k-means+	改进 k-means
			轻量化	轻量化	轻量化
			YOLOv4	YOLOv4	YOLOv4
飞机	86.04%	86.29%	86.01%	86.73%	86.73%
油桶	96.10%	95.06%	95.60%	96.32%	96.32%
立交桥	73.39%	71.76%	79.91%	87.57%	87.57%
操场	95.83%	98.92%	99.17%	99.37%	99.37%
mAP	87.84%	88.01%	90.17%	92.50%	92.50%

由图 6 和表 4 可以看出,针对样本量丰富的公共数据集,改进 k-means 且轻量化 YOLOv4 的检测精度较原算法提高了 5.3%,验证了本文改进算法有效性。

4.2 基于无人机数据集的目标检测实验

4.2.1 无人机数据集

无人机数据集所需图片来源于网络爬虫和手机拍摄,通过数据增强的方式增加图片的数量,包括翻转、旋转、缩放比例、裁剪、移位、加入高斯噪声和颜色增强^[17]。并运用图像标注工具 labeling 进行数据集的制作^[18],数据集格式为 Pascal VOC,数据集分为 uav 和 uav1 等 2 类共 1000 张图片,2 类各有 500 张。数据集制作情况如图 7 所示。



(a) 数据集标注图片



(b) 标注图片的 XML 文件

图 7 数据集制作

Fig.7 Data set production

4.2.2 无人机数据集实验结果及分析

4.2.2.1 YOLOv3 和 YOLOv4 检测结果及分析

分别利用传统的 YOLOv3 和 YOLOv4 算法在单无人机(uav)和无人机集群(uav1)2 种情况下进行检测,检测结果如图 8 和图 9 所示。



(a) 单个 uav 检测结果 (b) 集群 uav1 检测结果

图 8 YOLOv3 无人机的检测结果

Fig. 8 Test results of yolov3 UAV



(a) 单个 uav 检测结果 (b) 集群 uav1 检测结果

图 9 YOLOv4 无人机的检测结果

Fig. 9 Test results of yolov4 UAV

表 5 不同 IOU 下 YOLOv3 算法 AP 值和 mAP 值
Tab.5 AP value and map value of yolov3 algorithm under different IOU

类别	AP	AP ₆₀	AP ₇₀	AP ₈₀	AP ₉₀
uav	77.06%	65.57%	56.58%	42.01%	33.59%
uav1	88.74%	74.78%	61.51%	49.48%	36.92%
F1-uav	0.79	0.59	0.43	0.30	0.23
F1-uav1	0.92	0.67	0.53	0.37	0.25
mAP	82.90%	70.17%	59.05%	45.75%	35.25%

表 6 不同 IOU 下 YOLOv4 算法 AP 值和 mAP 值
Tab.6 AP value and map value of yolov4 algorithm under different IOU

类别	AP	AP ₆₀	AP ₇₀	AP ₈₀	AP ₉₀
uav	91.56%	88.50%	85.35%	74.99%	60.35%
uav1	88.27%	88.78%	85.29%	76.17%	54.11%
F1-uav	0.89	0.84	0.78	0.49	0.34
F1-uav1	0.92	0.87	0.68	0.52	0.33
mAP	89.91%	88.64%	85.32%	75.58%	57.23%

由图 8 和图 9 可以看出，在无人机检测中出现漏检和误检情况，进一步结合表 5、表 6 可见，当 IOU 的数值由小变大时，F1 指标不断降低，表明无人机集群的正负样本分类难度增加，无人机集群的检测难度越来越大，对应的 mAP 值越来越低。而在相同条件下，YOLOv4 相比 YOLOv3 算法有更高的平均检测精度。

4. 2. 2. 2 基于轻量化网络的 YOLOv4 检测结果及分析

使用轻量化网络和 YOLOv4 默认先验框，进行无人机检测所得结果如图 10 和表 7 所示。



(a) 单个 uav 检测结果 (b) 集群 uav1 检测结果

图 10 基于轻量化网络的 YOLOv4 无人机的检测结果

Fig.10 Detection results of yolov4 UAV Based on lightweight network

表 7 轻量化网络下不同 IOU 所对应的 AP 值以及 mAP 值
Tab.7 AP values and map values corresponding to different ious under lightweight network

类别	AP	AP ₆₀	AP ₇₀	AP ₈₀	AP ₉₀
uav	95.02%	96.54%	93.27%	80.66%	68.17%
uav1	84.63%	84.38%	78.18%	72.02%	58.04%
F1-uav	0.88	0.88	0.79	0.53	0.37
F1-uav1	0.89	0.87	0.77	0.64	0.51
mAP	89.82%	90.46%	85.73%	76.34%	63.10%

对比图 9、图 10 和表 6、表 7 可知，使用轻量化的检测网络进行集群检测试验，可以看出与原网络检测精度基本保持不变。

4. 2. 2. 3 基于改进 K-means 聚类先验框的 YOLOv4 检测结果及分析

在 YOLOv4 基础上分别利用 K-means 和改进 K-means 聚类先验框改进算法，检测结果分别如图 11、图 12 和表 8、表 9 所示。



(a) 单个 uav 检测结果 (b) 集群 uav1 检测结果

图 11 基于 K-means 聚类先验框的改进 YOLOv4 检测结果

Fig.11 Improved yolov4 detection results based on K-means clustering a priori box



(a) 单个 uav 检测结果



(b) 集群 uav1 检测结果

图 12 基于改进 K-means 聚类先验框改进 YOLOv4 检测结果

Fig.12 Improved yolov4 detection results based on improved k-means clustering a priori box

表 8 K-means 先验框下不同 IOU 所对应的 AP 值以及 mAP 值
Tab.8 AP values and map values corresponding to different ious under K-means a priori box

类别	AP	AP ₆₀	AP ₇₀	AP ₈₀	AP ₉₀
uav	92.00%	91.85%	88.61%	77.18%	64.22%
uav1	94.67%	91.03%	85.50%	78.15%	68.05%
F1-uav	0.92	0.92	0.84	0.61	0.43
F1-uav1	0.95	0.87	0.67	0.46	0.34
mAP	93.33%	91.44%	87.05%	77.67%	66.14%

表 9 改进 K-means 先验框下不同 IOU 对应 AP 值及 mAP 值
Tab.9 AP values and map values corresponding to different ious under the improved k-means a priori frame

类别	AP	AP ₆₀	AP ₇₀	AP ₈₀	AP ₉₀
uav	96.15%	96.01%	93.03%	77.38%	66.38%
uav1	96.88%	96.48%	94.10%	81.92%	68.10%
F1-uav	0.96	0.96	0.92	0.59	0.42
F1-uav1	0.95	0.90	0.71	0.49	0.35
mAP	96.51%	96.25%	93.57%	79.65%	67.24%

由图 11、图 12 可以看出，利用改进 K-means 先验框使算法在单无人机检测中获得了更好的检测效果。由表 5-表 9 可以看出，改进的 K-means 先验框使无人机检测精度相比传统 YOLOv4 和基于 K-means 先验框的改进 YOLOv4 算法分别提高了 7.3% 和 3.4%，相比 YOLOv3 提高了 16.4%，表明改进 K-means 先验框可有效提高无人机检测效果。

4.2.2.4 检测精度与漏检率、误检率关系及分析

由图 8-图 12 可以清晰看出，在单无人机和无人机集群检测时，出现无人机的漏检和误检情况，并随着算法的改进，漏检和误检情况得到明显的改善，为了进一步定量分析，进行实验可得检测精度与漏检率、误检率关系如表 10 所示。

表 10 检测精度与漏检率、误检率关系
Tab.10 Relationship between detection accuracy, missed detection rate and false detection rate

类别	mAP	漏检率	误检率
YOLOv3	82.90%	9.62%	17.91%
YOLOv4	89.91%	3.23%	14.31%
轻量化 YOLOv4	89.82%	7.61%	15.5%
k-means+轻量化 YOLOv4	93.33%	3.70%	8.90%
改进 k-means+轻量化 YOLOv4	96.51%	3.03%	5.41%

由表 10 可以看出，当检测精度为 96.51%，改进的 YOLOv4 算法，相比较 YOLOv3 和 YOLOv4，漏检率分别降低了 68.5%、6.25%，误检率分别降低了 69.8%、62.2%，有效地解决了无人机检测中误检、漏检情况。

4.2.2.5 综合 2 种改进策略下的检测结果及分析

使用轻量化网络，并同时采用改进 K-means 聚类先验框 2 种手段对 YOLOv4 算法进行改进，对无人机集群进行检测实验，相同条件下，比较算法训练的检测模型、处理图片所需时间、检测速率 FPS 以及检测精度 mAP，其具体的实验结果如表 11 所示。

表 11 融合实验无人机集群检测实验结果

Tab.11 Test results of UAV cluster detection in fusion experiment

类别	检测模型 (MB)	时间 (s)	FPS	mAP
YOLOv3	235	0.068	14.76	82.90%
YOLOv4	244	0.084	11.84	89.91%
改进 YOLOv4	53.6	0.037	26.87	96.51%

由表 11 可得，改进 YOLOv4 算法得到的检测模型大小约为原算法 1/9，有效提高了检测速率，其中改进 YOLOv4 分别为 YOLOv3 和 YOLOv4 的 1.82 倍、2.27 倍；同时在保证检测速率的前提下，检测精度则分别提高了 16.4%、7.3%。

4.2.2.6 基于不同检测算法的检测结果及分析

为了进一步对比基于深度学习不同的目标检测算法在无人机集群检测中的效果，分别利用 SSD、Centernet、YOLOv4 和改进 YOLOv4 算法，基于 uav1 组成简单无人机集群进行目标检测实验，具体的实验结果如图 13 所示。

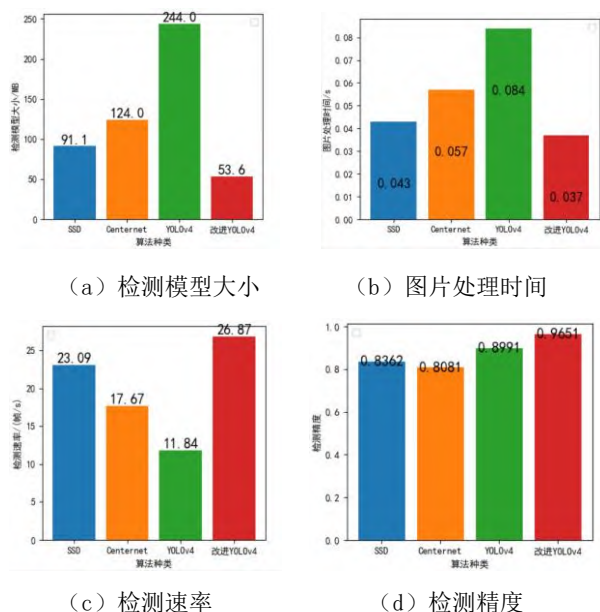


图 13 不同深度学习算法检测对比分析

Fig. 13 Comparative analysis of different depth learning algorithms

由图 13 可以看出,改进 YOLOv4 算法同时提高了检测精度和检测速率,与其他深度学习算法 SSD 和 Centernert 相比,检测精度分别提高了 15.4%、19.4%,检测速率分别提高了 16.4%、52.1%。

5 结论

相比传统 YOLOv3 和 YOLOv4 算法,改进的 YOLOv4 算法在无人机集群检测方面提高了检测精度和检测速度。算法能有效解决无人机集群检测中出现的误检和漏检等问题,能够较好地满足无人机集群对空作战所需的检测精度和检测速度。

参考文献

- [1] Lmez E, Akdoan V, Korkmaz M, et al. Automatic Segmentation of Meniscus in Multispectral MRI Using Regions with Convolutional Neural Network (R-CNN) [J]. *Journal of Digital Imaging*, 2020, 33(30):916-929.
- [2] Jain P K, Gupta S, Bhavsar A, et al. Localization of common carotid artery transverse section in B-mode ultrasound images using faster RCNN: a deep learning approach[J]. *Medical & Biological Engineering & Computing*, 2020, 58(3):471-482.
- [3] Chen X, Yu J, Wu Z. Temporally Identity-Aware SSD With Attentional LSTM[J]. *IEEE Transactions on Cybernetics*, 2020, 50(6): 2674 - 2686.
- [4] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]//

Computer Vision & Pattern Recognition. IEEE, 2016.

[5] Redmon J, Farhadi A. YOLO9000: Better, Faster, Stronger[C]// *IEEE Conference on Computer Vision & Pattern Recognition*. IEEE, 2017:6517-6525.

[6] Redmon J, Farhadi A. YOLOv3: An Incremental Improvement [EB

/OL]. 2021-08-14. <https://arxiv.org/pdf/1804.02767.pdf>.

[7] Bochkovskiy A, Wang C Y, Liao H Y M. YOLOv4: Optimal Speed and Accuracy of Object Detection[EB/OL]. 2021-08-14. <https://arxiv.org/abs/2004.10934v1>.

[8] Cai K W, Miao X Y, Wang W, et al. A modified YOLOv3 model for fish detection based on MobileNetv1 as backbone [J]. *Aquacultural Engineering*, 2020, 91:102117.

[9] Kundu S, Nazemi M, Pedram M, et al. Pre-defined Sparsity for Low-Complexity Convolutional Neural Networks[J]. *IEEE Transactions on Computers*, 2020, 69(7):1045-1058.

[10] Back S, Lee S, Shin S, et al. Robust Skin Disease Classification by Distilling Deep Neural Network Ensemble for the Mobile Diagnosis of Herpes Zoster[J]. *IEEE Access*, 2021, 9: 20156 - 20169.

[11] Chao G. Discriminative K-Means Laplacian Clustering[J]. *Neural Processing Letters*, 2019, 49(1):393-405.

[12] Zhu Q, Zheng H, Wang Y, et al. Study on the Evaluation Method of Sound Phase Cloud Maps Based on an Improved YOLOv4 Algorithm[J]. *Sensors*, 2020, 20(15):4314.

[13] Li X, Tian M, Kong S, et al. A modified YOLOv3 detection method for vision-based water surface garbage capture robot[J]. *International Journal of Advanced Robotic Systems*, 2020, 17(3):172988142093271.

[14] Yilmazer R, Birant D. Shelf Auditing Based on Image Classification Using Semi-Supervised Deep Learning to Increase On-Shelf Availability in Grocery Stores[J]. *Sensors*, 2021, 21(2):327.

[15] Li Y, Guo J, Guo X, et al. A Novel Target Detection Method of the Unmanned Surface Vehicle under All-Weather Conditions with an Improved YOLOV3[J]. *Sensors*, 2020, 20(17):4885.

[16]Yulin T , Jin S , Bian G , et al. Shipwreck Target Recognition in Side-Scan Sonar Images by Improved YOLOv3 Model Based on Transfer Learning[J]. *IEEE Access*, 2020, 8:173450-173460.

[17]Park M J , Ko B C . Two-Step Real-Time Night-Time Fire Detection in an Urban Environment Using Static ELASTIC-YOLOv3 and Temporal Fire-Tube[J]. *Sensors*

(Basel, Switzerland), 2020, 20(8): 2202.

[18]Tian D , Lin C , Zhou J , et al. SA-YOLOv3: An Efficient and Accurate Object Detector Using Self-Attention Mechanism for Autonomous Driving[EB/OL]. 2020-12-17/2021-08-14, <https://ieeexplore.ieee.org/document/9298480>.

